ANÁLISE DE NOTÍCIAS NO MERCADO FINANCEIRO: APLICAÇÃO DE LLMs PARA IDENTIFICAÇÃO DE OPORTUNIDADES E SINAIS DE COMPRA E VENDA

Estudante: Quele da Silva Andrade
Professor: Dr. Igor Dantas dos Santos Miranda
Disciplina: Metodologia da Pesquisa
Curso: Pós Graduação em Engenharia Elétrica e Computação

International Journal of
Human Computations & Intelligence
Vol. 04, Issue. 01, 2025

RESEARCH ARTICLE OPEN ACCESS

Dynamic Financial Sentiment Analysis and Market Forecasting through Large Language Models

Haranadha Reddy Busireddy Seshakagari[1] . Aravindan Umashankar[2] . T Harikala[3] . L Jayasree[4] . Jeffrey Severance

[1]Manager - Architecture, Valuemomentum, Erie, PA-16506, USA.
[2]Chief Strategy Officer, UpArrow Systems,1405, DAMAC Business Tower, Business Bay, Dubai.
[3]Dept of CSE, Annamacharya University, Rajampet, India.
[4]Dept of CSE, Sri Padmavati Mahila Visva Vidyalayam, Tirupati - 517 502, AP, India.
[5]Gannon University, Erie PA 16541, USA

DOI: **10.5281/zenodo.15111609**
Received: 11 February 2025 / Revised: 23 February 2025 / Accepted: 29 March 2025
©Milestone Research Publications, Part of CLOCKSS archiving

Abstract – Sentiment analysis is essential for determining public opinion, customer

Qual é o problema de pesquisa?

Limitações Atuais: Métodos tradicionais não conseguem processar o volume e a natureza não estruturada dos discursos financeiros modernos.

Complexidade do Domínio: Dificuldade em capturar conotações específicas e nuances técnicas da linguagem do mercado.

Dados Dinâmicos: A volatilidade das notícias financeiras exige uma interpretação em tempo real que modelos antigos não suprem com precisão.

Qual é a pergunta científica principal?

Pergunta: Como os modelos de linguagem de grande escala (LLMs) de última geração sendo eles: FinBERT, GPT-4 e T5 (Text-to-Text Transfer Transformer), se comparam na classificação de sentimentos do mercado financeiro?

Objetivo: Identificar qual arquitetura oferece o melhor equilíbrio entre precisão técnica, capacidade de generalização e aplicabilidade prática para decisões de investimento.

Qual é a contribuição do artigo?

Benchmarking Comparativo: Avaliação rigorosa entre modelos de domínio específico (FinBERT) vs. modelos generativos globais (GPT-4/T5).

Técnica SADA: Implementação de Sentiment-Aware Data Augmentation para resolver o desequilíbrio de classes nos dados.

Diretrizes de Aplicação: Definição de quais modelos são melhores para tarefas de "tempo real" vs. "análise profunda".

Estratégias de Mitigação: Métodos para lidar com ruídos e ambiguidades em textos financeiros.

Quais métricas foram usadas?

Para garantir a precisão dos resultados, foram utilizadas as seguintes métricas estatísticas:

- **Precisão (Precision):** Exatidão das classificações positivas.
- **Recall:** Capacidade de identificar todos os casos relevantes.
- **F1-Score:** Balanço harmônico entre Precisão e Recall.
- **Acurácia:** Porcentagem total de acertos nos conjuntos de treino e teste.
- **Matriz de Confusão:** Utilizada para visualizar erros e acertos específicos (destaque para o GPT-4).

O que torna a pergunta respondível?

A pesquisa é viável e respondível devido aos seguintes pilares:

- **Base de Dados Sólida:** Uso de um dataset anotado de 5.322 sentenças de notícias financeiras (via Kaggle).
- **Arquiteturas Diversificadas:** Comparação entre três LLMs distintas que permitem observar diferentes comportamentos de IA.
- **Processamento de Dados:** O uso de aumento de dados (SADA) garantiu que os modelos tivessem exemplos suficientes para aprender padrões raros.
- **Framework de Teste:** O uso de métricas padrão da indústria permite uma conclusão objetiva e quantificável

Quadro comparativo

PROBLEMA

Métodos tradicionais incapazes de processar notícias financeiras em escala

Volume não estruturado, nuances técnicas e volatilidade exigem interpretação em tempo real.

PERGUNTA

Qual LLM performa melhor na classificação de sentimento financeiro?

Comparação entre FinBERT, GPT-4 e T5 em precisão, generalização e aplicação prática.

CONTRIBUIÇÃO

Benchmarking + técnica SADA + diretrizes de uso

Modelo específico vs. generativos. Aumento de dados para classes raras. Guia tempo real vs. análise profunda.

MÉTRICAS

Precision, Recall, F1-Score, Acurácia e Matriz de Confusão

Avaliação objetiva nos conjuntos de treino e teste com destaque para erros do GPT-4.

EVIDÊNCIA

5.322 sentenças anotadas + framework experimental controlado

Dataset Kaggle, três arquiteturas distintas e SADA garantem resultados replicáveis.

Referência

SESHAKAGARI, Haranadha Reddy Busireddy et al. **Dynamic Financial Sentiment Analysis and Market Forecasting through Large Language Models.** International Journal of Human Computations & Intelligence, [s. l.], v. 4, n. 1, p. 397-410, 2025. Disponível em: https://doi.org/10.5281/zenodo.15111609. Acesso em: 28 mar. 2026.

Obrigada pela atenção.

contato: quele.andrade43@gmail.com

Table 3: Model Generalization Results Based on Training, Testing, and Validation Accuracy.

Model	Training	Testing	Validation
FinBERT	93.3	89.05	90.8
GPT-4	95.6	91.35	93.1
T5	93.0	88.75	90.5

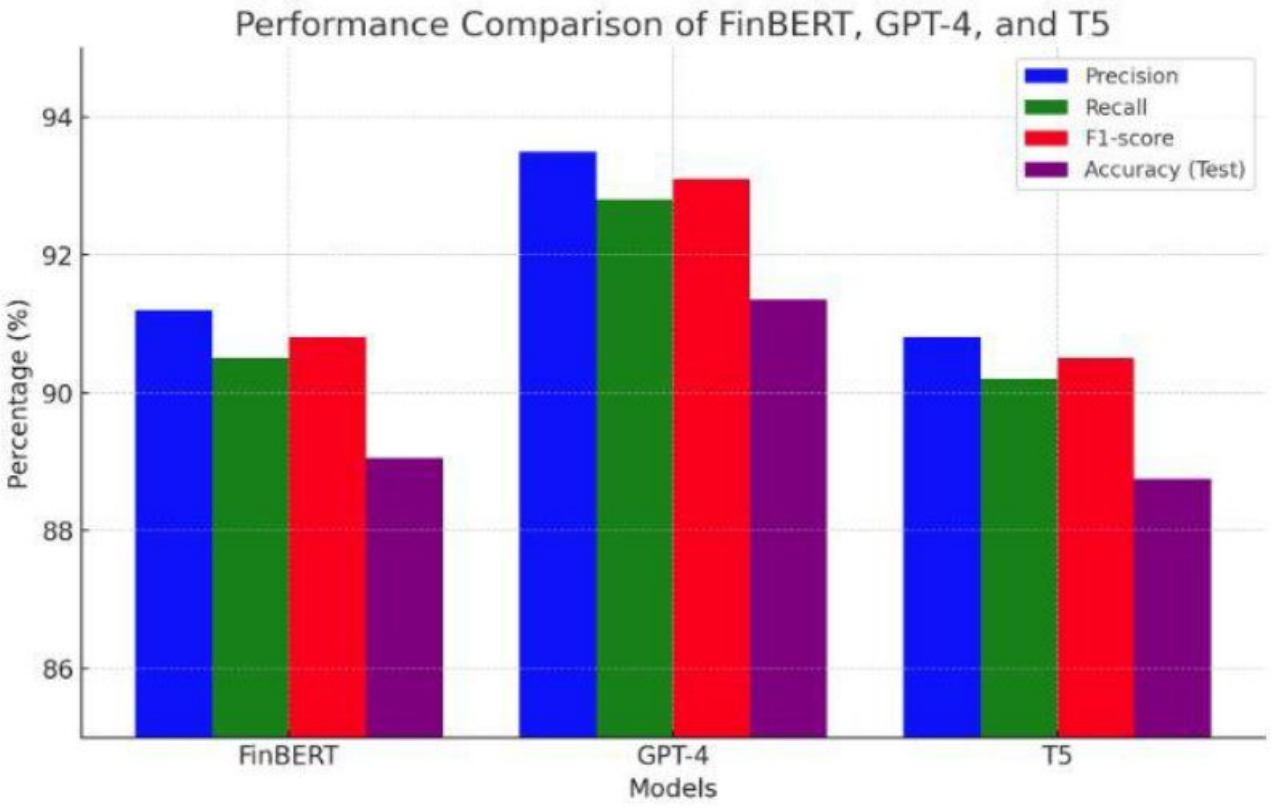

Fig. 4 : Performance comparison of all models