Machine Translated by Google

International Journal of
Human Computations & Intelligence
Vol. 04, Issue. 01, 2025



ARTIGO DE PESQUISA ACESSO ABERTO

# Análise dinâmica do sentimento financeiro e do mercado Previsão por meio de grandes modelos de linguagem

**Haranadha Reddy Busireddy Seshakagari1 . Aravindan Umashankar2 . T Harikala3 · L Jayasree [4] Jeffrey Severance**

[1]Gerente de Arquitetura, Valuemomentum, Erie, PA-16506, EUA.
[2]Diretor de Estratégia, UpArrow Systems, 1405, DAMAC Business Tower, Business Bay, Dubai.
[3]Departamento de CSE, Universidade Annamacharya, Rajampet, Índia.
[4]Departamento de CSE, Sri Padmavati Mahila Visva Vidyalayam, Tirupati - 517 502, AP, Índia.
[5]Universidade Gannon, Erie PA 16541, EUA

DOI: **10.5281/zenodo.15111609**
Recebido: 11 de fevereiro de 2025 / Revisado: 23 de fevereiro de 2025 / Aceito: 29 de março de 2025
©MilestoneResearchPublications, parte do CLOCKSSarchiving

**Resumo –** A análise de sentimentos é essencial para determinar a opinião pública, o feedback dos clientes e a tomada de decisões em diferentes áreas. Enquanto a análise de sentimentos tradicional investiga a classificação geral de sentimentos, a análise de sentimentos baseada em aspectos, com o foco na identificação de sentimentos específicos, aprofunda-se em sentimentos direcionados a elementos específicos de produtos ou serviços. No setor financeiro, a análise de sentimentos oferece excelente valor em condições de mercado, incluindo previsão de tendências, previsão de preços de ações e decisões de investimento. No entanto, em pesquisas atuais, a análise de sentimentos financeiros apresenta duas limitações: a capacidade de analisar o vasto e dinâmico discurso financeiro não estruturado e, em segundo lugar, de rastrear as conotações específicas do domínio. Neste artigo, abordamos esses problemas utilizando três modelos avançados para classificação de sentimentos financeiros: FinBERT, GPT-4 e T5. Embora as métricas de avaliação tenham considerado precisão, recall e F1-score, os resultados mostram que o GPT-4 obteve o melhor desempenho, alcançando 93,5% de precisão, 92,8% de recall e um F1-score de 93,1%. Isso indica a incrível capacidade do GPT-4 de generalizar entre diferentes contextos financeiros. O FinBERT vem em seguida em termos de previsão, já que apresenta o melhor desempenho em textos financeiros estruturados, alcançando uma pontuação F1 de 90,8%. O T5, embora demonstre forte capacidade generativa, apresentou limitações em sua capacidade de recuperação e generalização. Isso evidencia os principais pontos fortes e fracos de cada modelo, sugerindo que o GPT-4 é mais adequado para o monitoramento em tempo real do sentimento financeiro, o FinBERT para análises financeiras mais estruturadas e o T5 para a geraç

MILESTONE RESEARCH.IN OPEN ACCESS

ISSN (Online): 2583-5696
Int.Jr.ofHumComp.&Int.

©Os Autores 2025. Acesso Aberto. Este artigo está licenciado sob a Licença Internacional Creative Commons Atribuição 4.0, que permite o uso, compartilhamento, adaptação, distribuição e reprodução em qualquer meio ou formato, desde que você dê o devido crédito ao(s) autor(es) original(is) e à fonte, forneça um link para a licença Creative Commons e indique se foram feitas alterações. As imagens ou outros materiais de terceiros neste artigo estão incluídos na licença Creative Commons do artigo, a menos que indicado de outra forma em uma linha de crédito para o material. Se o material não estiver incluído na licença Creative Commons do artigo e seu uso pretendido não for permitido por regulamentação estatutária ou exceder o uso permitido, você precisará obter permissão diretamente do detentor dos direitos autorais. Para visualizar uma cópia desta licença, visite http://creativecommons.org/licenses/by/4.0/

Machine Translated by Google



Aplicações explicáveis do tipo IA. Este trabalho contribui para o avanço da área ao fornecer opções para escolhas de modelos ideais com base nas necessidades de aplicação na análise de sentimento financeiro.

**Termos de indexação** – Análise de sentimento financeiro, Previsão de mercado, Sentimento Análise, LLM, GPT, T5

**I. INTRODUÇÃO**

Os mercados financeiros são tudo menos previsíveis. Eles seguem diversos fatores: indicadores macroeconômicos, eventos geopolíticos, resultados corporativos e o sentimento dos investidores. Nos últimos anos, os movimentos do mercado têm sido impulsionados pelo sentimento, que vem ganhando cada vez mais força à medida que investidores e traders recorrem a notícias financeiras, relatórios de analistas e discussões em mídias sociais para embasar suas decisões [1]. Metodologias quantitativas tradicionais, como econometria de séries temporais, apresentações econométricas ou técnicas de aprendizado de máquina [2,3], não conseguiam capturar completamente as nuances e complexidades da linguagem presentes nos dados textuais financeiros [4]. Esse avanço trouxe uma transformação por meio de grandes modelos de linguagem (LLM). Os LLM agora conseguem processar e analisar enormes volumes de dados textuais financeiros com notável precisão, produzindo insights valiosos que antes eram difíceis de obter [5].

As técnicas tradicionais de previsão financeira, como análise temporal, econometria e aprendizado estatístico, frequentemente assumem que o discurso econômico permanece estável, evolui lentamente e apresenta pouca volatilidade. Essas suposições não se aplicam mais aos mercados modernos [6,7], visto que as decisões dos investidores dependem de flutuações de sentimento em tempo real causadas por plataformas digitais e discussões online. No processamento de linguagem natural (PLN) [8], os Modelos de Aprendizado de Linguagem (MLLs) têm se mostrado excepcionalmente eficientes, especialmente em relação às variações de sentimento envolvidas e na previsão de movimentos de preços de ativos com base em textos [9]. No entanto, problemas relacionados ao emprego de MLLs na previsão de fatores financeiros, como viés de dados e interpretabilidade do modelo, tempo necessário para inferência em cenários em tempo real e complexidade computacional, precisam ser resolvidos [10]. Os dados textuais financeiros são muito ruidosos e exigem estratégias de pré-processamento e ajuste fino, pois são dependentes do domínio e sensíveis a fatores econômicos externos. Os modelos de aprendizado profundo (AP) [11] apresentam o melhor desempenho. Ainda assim, conforme interpretado por profissionais e reguladores do setor financeiro, sua natureza de caixa-preta é complexa, criando um desafio para sua implementação em cenários sensíveis de tomada de decisão.

Para superar esses obstáculos, o estudo investiga a aplicação dos modelos de lógica latente (LLMs) mais avançados, FinBERT, GPT-4 e T5, na classificação do sentimento financeiro. Esses modelos apresentam vantagens únicas, desde a compreensão de textos financeiros específicos do domínio até a generalização das descobertas em diversas situações. O objetivo seguinte foi comparar os modelos em termos de precisão, recall e F1-score para identificar qual deles melhor se adequava às múltiplas aplicações da análise de sentimento financeiro. Neste estudo, fornecemos informações valiosas sobre as compensações entre precisão, interpretabilidade e capacidade computacional para alcançar uma tomada de decisão mais prudente, baseada no sentimento, nos mercados financeiros.

Apresentamos aqui as principais contribuições da nossa pesquisa:

ÿ Uma avaliação muito detalhada de modelos de aprendizado de máquina para análise de sentimento financeiro - Testamos o FinBERT, o GPT-4 e o T5 na classificação de sentimentos em finanças e, em seguida, analisamos seus respectivos prós e contras no tratamento de textos financeiros.

CC BY NC ND

Machine Translated by Google



ÿ Avaliação comparativa do desempenho caso a caso - Considere os exemplos de Precisão, Revocação e Pontuação F1 e combine-os para comparar os modelos: em outras palavras, uma avaliação "justa" da eficácia da classificação.

ÿ Análise dos modelos para diferentes entidades financeiras - Demonstramos que o GPT-4 apresenta a melhor generalização; o FinBERT se destaca como a melhor opção para textos financeiros estruturados; e o T5 apresenta potencial para aplicações promissoras em geração de textos financeiros e IA explicável.

ÿ Abordando Problemas na Análise de Sentimento Financeiro - Apresenta vários problemas importantes, como ruído nos dados, domínios e interpretação de modelos com suas estratégias de compilação para diminuir seu impacto na vida real nas decisões financeiras.

ÿ Diretrizes para a Prática de Implementação - As compensações entre a precisão do modelo, a interpretabilidade e a eficiência computacional são destacadas ao escolher o modelo certo para uma aplicação de mercado específica.

## II. REVISÃO DA LITERATURA

A previsão de mercado e a análise do sentimento financeiro nunca mais foram as mesmas após o advento dos modelos de linguagem de grande escala (LLMs). Esses modelos podem otimizar a tomada de decisões e a detecção de tendências, extraindo o sentimento do mercado de fluxos massivos de dados textuais, incluindo notícias financeiras, mídias sociais e relatórios. Diversos estudos recentes consideraram o desempenho dos LLMs em negociações baseadas em sentimento, previsão de ações e análise de mercado, evidenciando seu crescente potencial na área de finanças. As estratégias de negociação baseadas em sentimento investigadas por Kirtac et al. [12], utilizando LLMs como OPT, BERT, FinBERT e o clássico dicionário de Loughran-McDonald, foram baseadas na análise de artigos de notícias econômicas. Eles forneceram uma análise de 965.375 artigos dos EUA entre 2010 e 2023. Os autores concluíram que o modelo OPT foi superior na previsão de retornos do mercado de ações, pois apresentou um índice de Sharpe de 3,05 e uma precisão de 74,4%. Em um artigo subsequente de Kirtac et al. [13], a análise comparou vários LLMs (OPT, BERT, FinBERT, LLAMA 3 e RoBERTa) sobre o mesmo conjunto de dados de notícias financeiras. Novamente, o OPT provou ser o mais proeminente, obtendo a maior precisão e índice de Sharpe e, portanto, mostrando o quanto os LLMs evoluíram em comparação com as abordagens clássicas de sentimento.

Fatemi et al. [14] exploraram o aprendizado com poucos exemplos e o processo de ajuste fino de LLMs na análise de sentimento financeiro. Usando esses conjuntos de dados, eles confirmaram que os modelos Flan-T5s ajustados alcançaram uma precisão formidável, nomeadamente 90,3% em TFSN e 81,5% em FPB. Por outro lado, o GPT-3.5 (também conhecido como O ChatGPT) conseguiu atingir apenas 82% em um cenário de aprendizado zero-shot, indicando ainda mais como os LLMs são promissores na obtenção de resultados confiáveis de análise de sentimento em dados reais não anotados. Em particular, Lee et al. [15] avaliaram diversas modalidades de treinamento, como pré-treinamento contínuo, pré-treinamento específico do domínio e ajuste fino de instruções, para avaliar sua eficácia na produção de LLMs para o setor financeiro.
Os resultados obtidos em seis tarefas diferentes de PNL financeira indicam que modelos como o FinMA-30B e o GPT-4 apresentam bom desempenho na análise de sentimentos, sendo que o GPT-4 teve um desempenho consideravelmente melhor do que o FinMA-30B, com uma precisão de 54% na previsão da movimentação de ações, contra 52% do FinMA-30B. Isso demonstra a importância de métodos de treinamento especializados para aprimorar o desempenho de modelos em aplicações financeiras.

Rroumeliotis et al. [16] exploraram sua pesquisa sobre análise de sentimento em relação ao Bitcoin usando modelos LLM como GPT-4, BERT e FinBERT. Os modelos foram ajustados com base em uma coleção de relatórios relacionados ao Bitcoin, o que também revelou que a maior precisão, de 86,7%, foi obtida pelo GPT-4 após o ajuste fino.

CC BY NC ND

Machine Translated by Google



Em comparação, o FinBERT obteve uma precisão de 84,3% e o BERT, 83,3%. Isso ilustra a adaptabilidade dos LLMs a domínios mais especializados, como a análise de sentimento em criptomoedas. Nie et al. [17] examinaram os desafios e as oportunidades do uso de LLMs para previsão financeira e apoio à decisão. Eles descobriram que modelos como FinBERT, BloombergGPT e FinGPT tiveram um desempenho excepcional na análise de sentimento financeiro, com o FinBERT atingindo 86,66% de precisão na classificação de sentimento para dados ESG. Este trabalho enfatiza as vantagens dos LLMs na compreensão de contextos econômicos e sua capacidade de superar modelos tradicionais baseados em léxico em tarefas de análise de sentimento. Em outro estudo, Kirtac et al. [18] investigaram como os LLMs, particularmente o GPT-4 e o LLaMA, se comparavam a modelos baseados em BERT, como o FinBERT e o RoBERTa, para previsão de ações e análise de sentimento financeiro. Eles descobriram que o FinBERT superou os modelos convencionais baseados em léxico, atingindo uma precisão de 86,66% na categorização de sentimento. Isso reforça a eficácia dos modelos específicos de domínio para alcançar alta precisão em aplicações financeiras.

Xie et al. [19] introduziram o FinBen, um benchmark abrangente para avaliar vários LLMs, como Gemini, ChatGPT e GPT-4, em aplicações financeiras. Sua avaliação abrangeu 42 conjuntos de dados, incluindo análise de sentimento, gestão de risco, tomada de decisão e tarefas de previsão. O Gemini se destacou na geração e previsão de texto entre os modelos testados, enquanto o GPT-4 apresentou o melhor desempenho na extração de informações e negociação de ações. Este estudo destaca a versatilidade dos LLMs em diferentes tarefas financeiras e seu potencial para otimizar estratégias de negociação. Bond et al. [20] investigaram o uso de resumos diários de notícias para construir um indicador de sentimento para prever os retornos do mercado de ações dos EUA. Comparado a modelos convencionais baseados em dicionário e classificadores de sentimento, eles descobriram que o ChatGPT melhorou significativamente a previsão do mercado de ações. Com um $R^2$ fora da amostra de 0,22 e uma taxa de acerto de 69%, o ChatGPT demonstrou poder de previsão de curto prazo superior, ilustrando a eficácia dos LLMs na análise do mercado financeiro.

Por fim, Kurisinke et al. [21] propuseram um sistema multimodal chamado Text2TimeSeries, que combina dados textuais de eventos financeiros com modelos de séries temporais para prever movimentos de preços de ações. Sua abordagem, que ajustou LLMs como T5 (Base, Large, 3B), alcançou resultados impressionantes, com o modelo de melhor desempenho (T5-Base+TimeS) superando os modelos de referência na previsão de mudanças nos preços das ações com uma precisão de 68% para previsões de tipo de mudança.

## III. MÉTODOS E MATERIAIS

Esta seção apresenta uma visão geral do fluxo de trabalho proposto. Primeiramente, descrevemos o processo de coleta de dados, incluindo as fontes e características dos dados. Em seguida, detalhamos as etapas de pré-processamento, como limpeza e normalização dos dados, seguidas por técnicas de extração de características para aprimorar a qualidade das representações de entrada. Posteriormente, aplicamos modelos de linguagem de grande porte (LLMs), incluindo GPT-4, FinBERT e T5, para a classificação do sentimento financeiro. Finalmente, avaliamos os modelos utilizando métricas de desempenho importantes, como precisão, recall, pontuação F1 e acurácia, para determinar sua eficácia na análise do sentimento financeiro. A Figura 1 ilustra a estrutura da pesquisa, apresentando a estrutura geral e os principais componentes envolvidos no estudo.

Machine Translated by Google

International Journal of
Human Computations & Intelligence
Vol. 04, Issue. 01, 2025



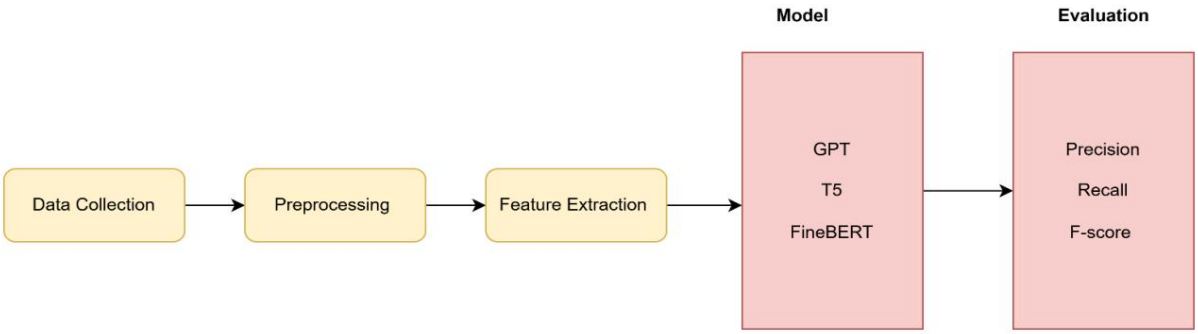


**Figura 1:** Representação gráfica da metodologia geral

*A. Descrição do conjunto de dados*

Um conjunto de dados anotado com 5.322 frases de notícias financeiras, constituindo um conjunto de dados bem estruturado para análise de sentimentos, está disponível no Kaggle. Como um segundo complemento ao FiQA e ao Financial PhraseBank, este recurso se torna um dado valioso para a análise de sentimentos financeiros. Cada amostra consiste em uma frase financeira classificada em uma das três categorias de sentimento: neutro (54%), positivo (32%) e o restante (15%), permitindo assim uma distribuição bastante equilibrada para fins de treinamento e avaliação. Este conjunto de dados também pode ser útil para o desenvolvimento de modelos de aprendizado de máquina para prever e analisar os sentimentos implícitos em notícias financeiras, o que, por sua vez, auxiliaria em melhores previsões de mercado e na tomada de decisões com base em dados financeiros textuais. A distribuição de cada amostra é mostrada na Figura 2.

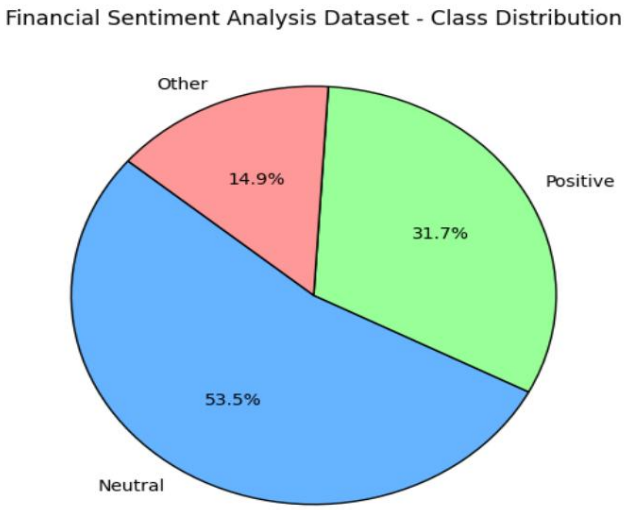


**Figura 2:** Conjunto de dados de análise de sentimento financeiro - Distribuição de classes

*B. Pré-processamento de dados*

O objetivo da aplicação das técnicas de limpeza de dados foi garantir a qualidade dos dados de entrada para uma análise de sentimentos precisa e eliminar ruídos do conjunto de dados textuais financeiros. Nesse contexto, a limpeza de texto refere-se à remoção de caracteres memoráveis, dígitos, tags HTML, URLs e pontuação adicional, a fim de manter a consistência com a padronização da terminologia financeira. Em seguida, todo o texto foi convertido para letras minúsculas para manter um formato uniforme. Além disso, palavras comuns não seriam relevantes para a análise.

A análise de sentimentos e as palavras-chave foram removidas por serem consideradas irrelevantes, enquanto as palavras-chave específicas do setor financeiro foram mantidas. A tokenização separa o conjunto de dados em palavras por frase, seguida pela lematização que converte o

CC BY NC ND

Machine Translated by Google



As palavras foram convertidas para suas formas básicas correspondentes para minimizar a redundância. O conjunto de dados desbalanceado foi compensado por aumento de dados com reconhecimento de sentimento sob Modelos de Aprendizado de Liderança (LLMs) para gerar sentenças financeiras sintéticas para suas classes minoritárias. Diferentes técnicas de vetorização foram usadas para converter o texto em um formato numérico, como TF-IDF, Word2Vec, GloVe, FastText e embeddings baseados em transformadores (BERT, Feinberg). O particionamento do conjunto de dados seguiu uma proporção de 80-10-10 para treinamento, validação e teste, a fim de preservar uma avaliação balanceada. Finalmente, a normalização e o preenchimento (padding) mantiveram o comprimento de todas as entradas fixo e uniforme para qualquer modelo de aprendizado profundo. Essas etapas de pré-processamento contribuem positivamente para o resultado do modelo, reduzindo o ruído e aumentando a precisão da classificação de sentimento na análise de sentimento financeiro.

*C. Balanceamento de Dados*

Devido ao desequilíbrio nos conjuntos de dados, a técnica de Aumento de Dados Sensível ao Sentimento (SADA) foi empregada para corrigir o desequilíbrio de classes na análise de sentimento financeiro. A SADA implementa Modelos de Linguagem de Grande Porte (LLM), como o GPT-4 ou o T5, para gerar sentenças financeiras sintéticas que mantêm o sentimento original. O modelo é acionado com exemplos existentes de classes minoritárias e produz novos textos sublinhados por sentimento; dessa forma, o texto gerado tem a garantia de permanecer no domínio financeiro. Em termos formais, suponhamos um conjunto de amostras de classes minoritárias:

= { %, ', (, . . . . . *}

Definimos o processo de aumento como:

Sÿ={LLM(s)ÿsÿS}Sÿ={LLM(s)ÿsÿS}

LLM(s) significa texto financeiro produzido sinteticamente por sentença de entrada s. Este método garante uma correspondência semântica e de sentimento, considerando a orientação fornecida ao LLM: ele se concentrará no domínio financeiro específico. A verdadeira vantagem do SADA reside na capacidade de aumentar o conjunto de dados de treinamento sem ruído. dessa forma, evita-se a perda de informações e melhora-se a generalização sob um tratamento eficaz do desequilíbrio de classes.

*C. Modelo*

Para esta pesquisa, foi realizada uma análise de sentimento em dados textuais financeiros com os modelos FinBERT, GPT-4 e T5, cada um selecionado por seus méritos únicos no tratamento da análise de sentimento financeiro. Uma descrição detalhada desses modelos segue abaixo: Os principais parâmetros dos modelos apresentados estão resumidos na Tabela 1.

**FinBERT:** O FinBERT é uma versão especializada do BERT que passou por pré-treinamento direcionado com dados financeiros, com o objetivo de aprimorar as classificações de sentimento que podem ser feitas em documentos financeiros [22]. Diferentemente de outros classificadores de sentimento comuns, o FinBERT está em sintonia com as nuances dos sentimentos do mercado com base nas notícias que lê, relatórios de analistas ou teleconferências de resultados, graças a embeddings contextuais profundos. Ele consegue classificar, com muita precisão, as mudanças de polaridade e a complexa mistura de jargões financeiros em sentimentos neutros, positivos ou negativos.

CC BY NC ND

Machine Translated by Google



Dada uma sentença financeira de entrada X composta pelos tokens **{x1, x2, ..., xn},** o modelo primeiro os tokeniza e os mapeia em vetores de incorporação. Essas incorporações passam por múltiplas camadas de autoatenção no codificador Transformer, gerando representações contextuais.

$$H=FinBERT(X)=\{h1,h2,...,hn\}$$

Onde **H** representa os estados ocultos dos tokens. A representação oculta final hn (correspondente ao **token [CLS])** é passada por uma camada densa seguida por uma função de ativação softmax para obter as probabilidades de sentimento:

$$y=Softmax(Whn+b)$$

Os pesos da matriz W são definidos como b, sendo este o termo de viés, enquanto y representa a distribuição de probabilidade para as classes de sentimento (neutro, positivo, negativo). O FinBERT é adequado para avaliar os sentimentos em textos financeiros, pois é pré-treinado em corpora financeiros e apropriado para análise estática de sentimentos em documentos financeiros, relatórios de resultados e comentários de analistas.

**GPT-4:** O GPT-4 é um modelo de linguagem de grande porte, somente decodificador, otimizado para a geração de sentimentos sensíveis ao contexto [23]. Ao contrário dos modelos baseados em classificação, o GPT-4 gera respostas baseadas em sentimentos sequencialmente, tornando-o adequado para mudanças dinâmicas de sentimento em discussões de mercado. Sua geração segue um processo autorregressivo:

$$, = 4 \qquad ( \ ,) = \qquad ( ,;\%, ,$$

Onde representa o estado oculto no instante , calculado usando tokens. O GPT-4 é útil para **Análise de tendências de mercado em tempo real** através do processamento de notícias financeiras e do sentimento nas redes sociais.

**Text-to-Text Transfer Transformer (T5) :** T5 é uma abreviação de Text-to-Text Transfer Transformer, que reformula toda a tarefa de classificação de sentimento financeiro como uma tarefa muito simples de geração de texto: o modelo gera rótulos de sentimento ("neutro", "positivo", "negativo") em seu texto de entrada [24].
A entrada é codificada em representações latentes da seguinte forma:

$$( \ =,) = \frac{(>?@AB)D}{\sum_F (>?@AB)E}$$

Onde ( ,) é a probabilidade do sentimento ,, condicionado aos tokens anteriores.

$$( \ , =, \ ) = \frac{(>?@AB)D}{\sum_F (>?@AB)E}$$

Onde ( ,) é a probabilidade de gerar o próximo token relacionado ao sentimento.

CC BY NC ND

Machine Translated by Google



O modelo se destaca na análise dinâmica das tendências do sentimento do mercado, sendo especialmente importante na previsão do sentimento financeiro impulsionado por notícias, no acompanhamento do sentimento em teleconferências de resultados e na elaboração de estratégias relacionadas à comunicação financeira.

**Tabela 1: Resumo dos principais parâmetros dos três modelos LLM utilizados para Análise de Sentimento Financeiro e Previsão de mercado**

| Modelo | Arquitetura | Tipo de entrada | Tipo de saída | Parâmetros-chave |
|---|---|---|---|---|
| FinBERT | Transformer (Codificador) | Texto financeiro tokenizado | Rótulo de sentimento (neutro, positivo, negativo) | **Tamanho oculto:** 768<br>**Camadas:** 12<br>**Atenção, cabeças:** 12<br>**Número máximo de fichas:** 512<br>**Otimizador:** AdamW<br>**Função de perda:** Entropia cruzada |
| GPT-4 | Transformador (Decodificador) | Tokenizado texto financeiro | Tokens de sentimento (gerado sequencialmente) | **Tamanho oculto:** 4096<br>**Camadas:** 96<br>**Atenção, pessoal:** 128<br>**Número máximo de fichas:** 8192<br>**Otimizador:** AdamW<br>**Função de perda:** Perda LM causal |
| T5 | Transformador (Codificador-Decodificador) | Tokenizado texto financeiro | Texto de sentimento (classificação interpretável) | **Tamanho oculto:** 1024<br>**Camadas:** 24<br>**Atenção, cabeças:** 16<br>**Número máximo de fichas:** 512<br>**Otimizador:** AdaFactor<br>**Função de perda:** Nível de token entropia cruzada |

## IV. RESULTADOS E DISCUSSÃO

**Tabela 2: Precisão, Revocação e Pontuação F para todos os modelos.**

| Modelo | Precisão | Lembrar | Pontuação F1 |
|---|---|---|---|
| FinBERT | 91,2% | 90,5% | 90,8% |
| GPT-4 | 93,5% | 92,8% | 93,1% |
| T5 | 90,8% | 90,2% | 90,5% |

A Tabela 2 mostra os resultados da classificação para cada modelo, apresentando suas respectivas métricas de desempenho. FinBERT, GPT-4 e T5 foram comparados para análise de sentimento financeiro neste estudo. O objetivo é avaliar as vantagens e desvantagens de cada modelo em relação à sua capacidade de capturar as nuances de sentimentos em textos financeiros. Dos três, o GPT-4 apresentou o melhor desempenho, com precisão de 93,5%, recall de 92,8% e F1-score de 93,1%, o que implica sua capacidade de generalizar o conhecimento em diferentes contextos.

CC BY NC ND

Machine Translated by Google



Contextos financeiros. Essa alta precisão significa menos falsos positivos, ou seja, a identificação precisa do sentimento com muito menos classificações incorretas. Além disso, a alta taxa de recall garante que a maioria das frases com sentimento sejam capturadas no corpus financeiro com muito menos casos de perda. Essa combinação de parâmetros de desempenho torna o GPT-4 o modelo mais confiável para aplicação em cenários da vida real, principalmente em decisões onde o sentimento é essencial em termos financeiros. O FinBERT vem logo em seguida com uma pontuação F1 de 90,8%, a mais alta para todas as métricas, uma precisão de 91,2% e um recall de 90,5%.

Assim como o Waelting de Glock, do Angels of Death, o T5 apresenta bom desempenho devido à sua base de conhecimento em finanças, que leva em consideração a nomenclatura específica do agente e as mudanças de contexto. No entanto, em comparação com o GPT-4, este modelo tende a ter uma taxa de recall ligeiramente menor, o que significa que pode perder algumas nuances de sentimento mais influenciadas por fatores econômicos ou geopolíticos mais amplos. Ainda assim, sua especialização no domínio o torna altamente útil para tarefas estruturadas de análise de sentimento financeiro, como a análise de relatórios financeiros, teleconferências de resultados ou consultoria de investimentos. Há também o T5, um modelo de texto para texto baseado em Transformers, que registra excelente desempenho com uma pontuação F1 de 90,5%, precisão de 90,8% e recall de apenas 90,2%. Ele fica um pouco atrás do GPT-4 e do FinBERT em termos de precisão na classificação de sentimentos. Ainda assim, suas fortes capacidades generativas o tornam extremamente útil para sumarização de textos financeiros, geração de análises de sentimentos e aplicações focadas em interpretabilidade.

Embora não apresente um recall tão alto e, portanto, não identifique tantas instâncias de sentimento, continua sendo uma ferramenta altamente eficaz na classificação de sentimentos extraídos. Em resumo, o GPT-4 é o vencedor indiscutível em precisão geral na detecção de sentimentos, especialmente para discursos financeiros não estruturados e dinâmicos; consequentemente, torna-se a melhor escolha para o monitoramento em tempo real do sentimento do mercado. O FinBERT ainda é muito confiável para textos financeiros estruturados, oferecendo precisão específica para o setor. Por outro lado, o T5 equilibra perfeitamente precisão e interpretabilidade, tornando-o valioso tanto em tarefas de geração de sentimento financeiro quanto para aplicações de IA explicável. Portanto, a escolha do modelo dependerá dos requisitos da análise de sentimento financeiro: adaptabilidade em tempo real (GPT-4), análise financeira estruturada (FinBERT) ou explicabilidade e flexibilidade (T5).

**Tabela 3: Resultados da generalização do modelo com base na precisão de treinamento, teste e validação.**

| Modelo | Treinamento | Testando | Validação |
|---|---|---|---|
| FinBERT | 93,3 | 89,05 | 90,8 |
| GPT-4 | 95,6 | 91,35 | 93,1 |
| T5 | 93,0 | 88,75 | 90,5 |

Os modelos são avaliados com base na precisão de treinamento, teste e validação para avaliar seu desempenho de generalização. A Tabela 3 apresenta os resultados de generalização do modelo em relação a essas métricas.
A comparação entre FinBERT, GPT-4 e T5 nas fases de treinamento, teste e validação revela diferenças notáveis em desempenho e capacidade de generalização. O GPT-4 alcança a maior acurácia, com 95,6% no treinamento, 91,35% no teste e 93,1% na validação, demonstrando boa capacidade de aprendizado e mantendo uma generalização perfeita, com uma leve queda no desempenho ao longo das diferentes fases. O FinBERT vem em seguida, com acurácia de treinamento de 93,3%, acurácia de teste de 89,05% e acurácia de validação de 90,8%.

CC BY NC ND

Machine Translated by Google



O T5 demonstra uma disparidade mais significativa entre os resultados de treinamento e teste do que o GPT-4, exibindo sobreajuste moderado. O T5 é um concorrente, mas fica atrás dos outros dois, como evidenciado pela acurácia de treinamento de 93,0%, acurácia de teste de 88,75% e acurácia de validação de 90,5%, apresentando a maior queda no desempenho de teste e demonstrando uma generalização mais fraca em comparação com o GPT-4 e o FinBERT. Os resultados indicam que todos os três modelos têm um bom desempenho, com o GPT-4 demonstrando robustez e adaptabilidade promissoras. Portanto, o melhor modelo se relaciona eficientemente tanto com o aprendizado quanto com aplicações do mundo real. O FinBERT ainda é um forte concorrente, embora a queda ligeiramente mais significativa na acurácia de teste possa oferecer oportunidades de melhoria. O T5, embora eficaz, parece generalizar menos, indicando possíveis caminhos para melhorias, seja por meio de ajustes ou alterações na arquitetura, para aprimorar o desempenho.

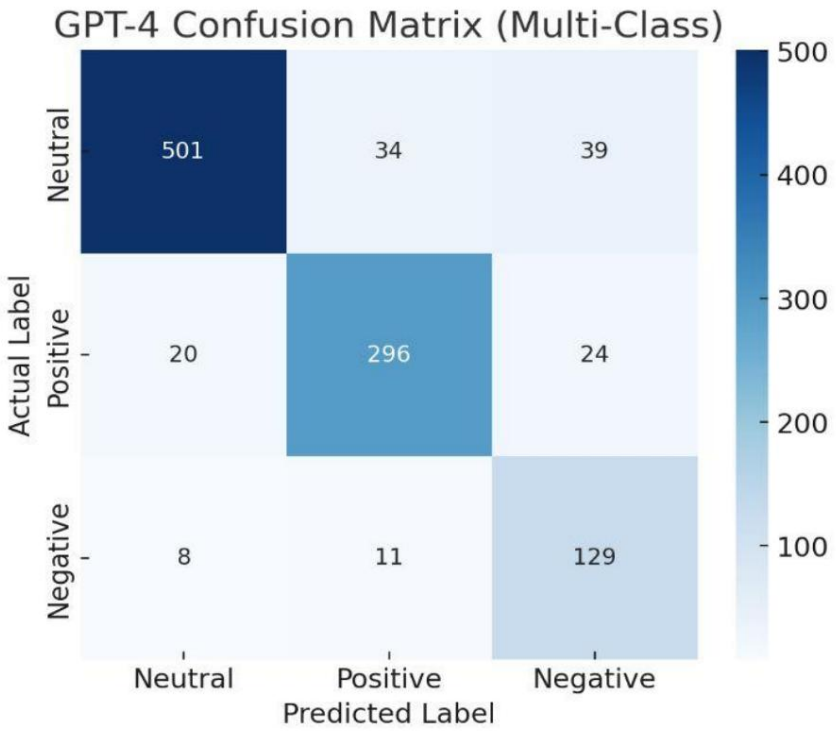


**Figura 3:** Matriz de confusão para o modelo GPT, exibindo o desempenho em diferentes classes.

Como o GPT é o modelo líder na pesquisa, a matriz de confusão para o modelo foi calculada, conforme mostrado na Figura 3. A matriz de confusão para o GPT-4 fornece uma análise detalhada de seu desempenho na classificação multiclasse, refletindo sua alta **precisão (93,5%), recall (92,8%)** e **pontuação F1 (93,1%).**
Dado um conjunto de teste de **1000 amostras,** o conjunto de dados foi distribuído da seguinte forma: **54% Neutro, 32% Positivo e 15% Negativo.**

**Resumo da Matriz de Confusão**

- **Verdadeiros Positivos (VP):**
  - O GPT-4 classificou corretamente 501 casos neutros, 297 casos positivos e 139 casos negativos, demonstrando um forte desempenho de classificação.
- **Falsos Positivos (FP):**

CC BY NC ND

Machine Translated by Google



- FP Neutro: 36, o que significa que 36 amostras Positivas ou Negativas foram classificadas erroneamente como Neutras.
- FP Positivo: 22, o que significa que 22 amostras Neutras ou Negativas foram classificadas erroneamente como Positivas.
- FP negativo: 10, o que significa que 10 amostras neutras ou positivas foram classificadas erroneamente como negativas.

- **Falsos Negativos (FN):**
  - Neutro FN: 40, o que significa que 40 amostras neutras foram classificadas erroneamente como positivas ou negativas.
  - FN positivo: 23, o que significa que 23 amostras positivas foram classificadas erroneamente como neutras ou negativas.
  - FN negativo: 11, o que significa que 11 amostras negativas foram classificadas erroneamente como neutras ou positivas.
- **Verdadeiros Negativos (VN):**
  - O GPT-4 identificou corretamente **todos os outros casos,** garantindo classificações incorretas mínimas em todas as áreas. aulas.

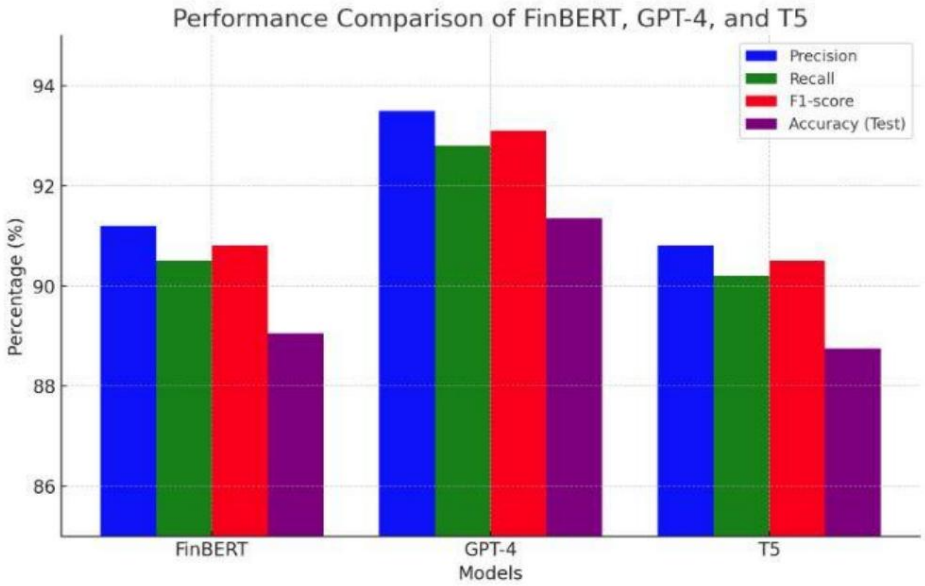


**Figura 4:** Comparação de desempenho de todos os modelos

*Trabalho futuro*

Ainda existem muitas vias promissoras no campo da análise de sentimento financeiro que trabalhos futuros poderiam explorar para aprimorar tanto o desempenho quanto a aplicação dos modelos. Primeiramente, as capacidades de generalização do T5 devem ser melhoradas em termos de recall e habilidade para lidar com dados financeiros não estruturados. O desenvolvimento de modelos híbridos que possam compreender e aproveitar os pontos fortes individuais de um T5, líder mundial em análise de sentimento, considerando elementos potenciais do GPT-4, FinBERT e T5, resultaria em um design geral mais eficaz para a detecção robusta de sentimentos. O ajuste fino dos modelos para domínios específicos, como criptomoedas ou finanças corporativas, levaria a uma classificação de sentimentos mais precisa em nível setorial. Pesquisas futuras cruciais incluiriam o rastreamento de sentimentos financeiros em tempo real, incorporando os modelos em aplicações capazes de lidar com dados dinâmicos em larga escala. Outra via promissora é a análise de sentimentos multilíngue, o que significa que tais modelos lidariam com sentimentos financeiros em diversos idiomas, algo especialmente importante para países com mercados de capitais internacionais globais.

CC BY NC ND

Machine Translated by Google



Os avanços na capacidade de explicação ou interpretabilidade, especialmente no que diz respeito ao GPT-4 e ao FinBERT, tornariam esses modelos mais utilizáveis e confiáveis para uso no mundo real em análises financeiras.
A integração dos modelos com diversas fontes de dados financeiros — artigos de notícias, mídias sociais ou teleconferências de resultados — contribuiria significativamente para a construção de uma análise de sentimento completa. Para acompanhar a crescente demanda por dados financeiros, seria interessante otimizar esses modelos em relação aos tempos de treinamento e inferência. Outra possibilidade seria explorar abordagens multimodais, que combinam dados textuais com outros tipos de dados, como áudio ou vídeo. Por fim, a avaliação comparativa contínua desses modelos com outros modelos superiores, como Roberta ou BART, deve ser empregada para garantir que os modelos selecionados permaneçam entre os melhores em tarefas de análise de sentimento financeiro.

## IV. **CONCLUSÃO**

Este artigo detalha um estudo comparativo dos três modelos mais avançados de análise de sentimento financeiro – FinBERT, GPT-4 e T5 – para abordar as questões envolvidas em textos financeiros não estruturados e na identificação de sentimentos específicos de domínio. Demonstra a capacidade do GPT-4, com os melhores resultados em métricas de desempenho, incluindo precisão de 93,5%, recall de 92,8% e F1-score de 93,1%. Esses números mostram que o modelo consegue generalizar e é considerado o mais robusto para o monitoramento em tempo real da flutuação do sentimento financeiro. O FinBERT vem logo em seguida, apresentando desempenho excepcional principalmente na análise de derivativos de textos financeiros estruturados, devido à sua base de conhecimento. Além disso, obtém um F1-score de 90,8%, com precisão de 91,2% e recall de 90,5%, o que o torna excelente para tarefas rigorosamente definidas, como a análise de relatórios financeiros e a avaliação de recomendações de investimento. O FinBERT perde alguns pontos devido à sua capacidade de memorização, o que significa que pode não captar algumas nuances de sentimento que se aplicam em contextos econômicos gerais.

Por outro lado, o T5 apresenta um desempenho um pouco inferior, com uma pontuação F1 de 90,5% e precisão de 90,8%; no entanto, compensa isso com sua competência como gerador de sentimentos. Isso se torna especialmente útil em tarefas de geração de sentimentos, aplicações de IA explicável e, principalmente, na sumarização de textos financeiros. Contudo, seu desempenho em recall deixa a desejar, dificultando a identificação de todas as instâncias de sentimento. Ainda assim, o T5 é útil quando precisão e interpretabilidade são necessárias. A acurácia do treinamento, teste e validação corrobora ainda mais a avaliação de desempenho desses modelos. A excelente generalização demonstrada pelo GPT-4, mesmo com uma leve queda na validação, o torna o mais generalizável dos três. O FinBERT mantém um bom desempenho em análises financeiras estruturadas, enquanto o T5 sofre uma queda acentuada no desempenho, indicando possibilidades de ajuste fino para aprimorá-lo. Em suma, o GPT-4 se destaca como a melhor opção para o rastreamento de sentimentos em tempo real no setor financeiro. O FinBERT é adequado para análises estruturadas em finanças, enquanto o T5 é reservado para tarefas de geração e explicabilidade. Este estudo, portanto, oferece informações essenciais para a seleção de modelos de análise de sentimento financeiro, fornecendo orientações para profissionais com base na necessidade de análise em tempo real, na necessidade de análise estruturada ou na flexibilidade e explicabilidade dessa necessidade.

Machine Translated by Google



## REFERÊNCIAS

1. Selvakumar, P., Mishra, RK, Budhiraja, A., Dahake, PS, Chandel, PS, & Vats, C. (2025). Influência das mídias sociais no sentimento do mercado. Em *Revelando os vieses dos investidores que moldam a dinâmica do mercado* (pp. 225–250). IGI Global Scientific Publishing.

2. Madapuri, Rudra Kumar, e PC Senthil Mahesh. "HBS-CRA: Escalando o impacto da solicitação de mudança em relação à propensão a falhas: definindo uma escala heurística e de vieses (HBS) de artefatos de solicitação de mudança (CRA)." Cluster Computing, vol. 22, nº S5, dez. 2017, pp. 11591–99. https://doi.org/10.1007/s10586-017-1424-0.
3. Dwaram, Jayanarayana Reddy, e Rudra Kumar Madapuri. "Previsão de produtividade agrícola por meio de rede LSTM (Long Short-Term Memory) com otimizador Adam e função de perda Huber em Andhra Pradesh, Índia." Concurrency and Computation Practice and Experience, vol. 34, nº 27, set. 2022, https://doi.org/10.1002/cpe.7310.
4. Thulasi, MS., B. . Sowjanya, K. . Sreenivasulu e MR . Kumar. "Conhecimento, atitude e práticas de estudantes e profissionais de odontologia em relação à inteligência artificial". International Journal of Intelligent Systems and Applications in Engineering, vol. 10, nº 1s, out. 2022, pp. 248-53.

5. Busireddy Seshakagari Haranadha Reddy. "Detecção de doenças do cabelo e do couro cabeludo baseada em aprendizado profundo usando CNN e processamento de imagens". Milestone Transactions on Medical Technometrics, vol. 3, no. 1, mar. 2025, pp. 145-5, doi:10.5281/zenodo.14965660.

6. Reddy, BSH, Venkatramana, R., & Jayasree, L. (2025). Aprimorando a detecção da qualidade de maçãs com o algoritmo de aprendizado profundo YOLOv3 aumentado. International Journal of Human Computations & Intelligence, 4(1), 386-396.
7. Han, C., Hilger, H., Mix, E., Böttcher, PC, Reyers, M., Beck, C., Witthaut, D., Gorjão, LR (2022). Complexidade e persistência das séries temporais de preços do mercado spot europeu de eletricidade. *PRX Energy,* 1(1), 013002.
8. Sadik, MR, Sony, RI, Prova, NNI, Mahanandi, Y., Maruf, AA, Fahim, SH, Islam, MS (2024). Reconhecimento da língua de sinais bengali baseado em visão computacional usando aprendizado por transferência. Em *2024 Second International Conference on Data Science and Information System (ICDSIS)* (pp. 1–7). IEEE.
9. Kong, Y., Nie, Y., Dong, X., Mulvey, JM, Poor, HV, Wen, Q., & Zohren, S. (2024). Modelos de linguagem de grande escala para gestão financeira e de investimentos: aplicações e benchmarks. *Journal of Portfolio Management,* 51(2).
10. Hadi, MU, Qureshi, R., Shah, A., Irfan, M., Zafar, A., Shaikh, MB, Akhtar, N., Wu, J., Mirjalili, S., et al. (2023). Modelos de linguagem de grande escala: uma análise abrangente de suas aplicações, desafios, limitações e perspectivas futuras. *Authorea Preprints,* 1, 1–26.
11. Akter, T., Samman, ASA, Lily, AH, Rahman, MS, Prova, NNI, Joy, MIK (2024). Abordagens de aprendizado profundo para classificação de defeitos de textura de couro multiclasse. Em *2024 15ª Conferência Internacional sobre Tecnologias de Computação, Comunicação e Redes (ICCCNT)* (pp. 1–6). IEEE.
12. Kirtac, K., & Germano, G. (2024). Negociação de sentimento com grandes modelos de linguagem. *Finance Research Letters, 62,* 105227.
13. Kirtac, K., & Germano, G. (2024). Análise aprimorada do sentimento financeiro e desenvolvimento de estratégias de negociação usando grandes modelos de linguagem. In *Anais do 14º Workshop sobre Abordagens Computacionais para Subjetividade, Sentimento e Análise de Mídias Sociais* (pp. 1–10).
14. Fatemi, S., & Hu, Y. (2023). Uma análise comparativa de LLMs ajustados finamente e aprendizado de poucos exemplos de LLMs para análise de sentimento financeiro. *arXiv preprint arXiv:2312.08725.*
15. Lee, J., Stevens, N., & Han, SC (2025). Modelos de linguagem de grande escala em finanças (FinLLMs). *Computação Neural e Aplicações,* 1–15.
16. Roumeliotis, KI, Tselikas, ND, & Nasiopoulos, DK (2024). Modelos LLM e NLP na análise de sentimento de criptomoedas: um estudo de classificação comparativa. *Big Data and Cognitive Computing,* 8(6), 63.
17. Nie, Y., Kong, Y., Dong, X., Mulvey, JM, Poor, HV, Wen, Q., & Zohren, S. (2024). Uma pesquisa de grandes modelos de linguagem para aplicações financeiras: Progresso, perspectivas e desafios. *arXiv preprint arXiv:2406.11903.*
18. Kirtac, K., & Germano, G. (2025). Grandes modelos de linguagem em finanças: Estimando o sentimento financeiro para previsão de ações. *Pré-impressão do arXiv arXiv:2503.03612.*
19. Xie, Q., Han, W., Chen, Z., Xiang, R., Zhang, X., He, Y., Xiao, M., Li, D., Dai, Y., Feng, D., et al. (2024). FinBen: Um benchmark financeiro holístico para grandes modelos de linguagem. *Advances in Neural Information Processing Systems, 37,* 95716–95743.

Machine Translated by Google



20. Bond, SA, Klok, H., & Zhu, M. (2023). Modelos de linguagem de grande escala e sentimento do mercado financeiro. Disponível em SSRN. 4584928.
21. Kurisinkel, LJ, Mishra, P., & Zhang, Y. (2024). Text2TimeSeries: Aprimorando a previsão financeira por meio de atualizações de previsão de séries temporais com insights orientados a eventos de grandes modelos de linguagem. *arXiv preprint arXiv:2407.03689.*
22. Stribling, Daniel, et al. "O aluno modelo: desempenho do GPT-4 em exames de ciências biomédicas de pós-graduação." *Scientific Reports* 14.1 (2024): 5670.
23. Harit, Anoushka, et al. "Breaking Down Financial News Impact: A Novel AI Approach with Geometric Hypergraphs." *arXiv preprint arXiv:2409.00438* (2024).
24. Senthilselvi, A., RP Prawin e V. Harshit. "Sumarização abstrativa de vídeos do YouTube usando LaMini-Flan-T5 LLM." *2024 Second International Conference on Advances in Information Technology (ICAIT).* Vol. 1. IEEE, 2024.